PROJET 3PDQ

Installation des packages

In [2]:
```
# Packages
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import scipy.stats as st
from sklearn.ensemble import IsolationForest
import warnings
# warnings.filterwarnings('ignore')
```

In [3]:
```
dataset = pd.read_csv("3PDQ - Feuil1.csv")
dataset
```

Out[3]:

	N°de_Patient	Centre	Initiales	Sexe	Age	Date_Naissance	Date_visite1	Date_visite2	EVA_mean	EVA_max	...	HADa.5	HADd.5	HADa.6	HADd
0	1	1	BM	M	71.0	juil.-46	2019/05/22	2019/05/22	50.0	60.0	...	0.0	0.0	0.0	0
1	2	1	BM	M	49.0	sept.-69	2019/06/28	2019/06/28	35.0	80.0	...	0.0	1.0	1.0	1
2	3	1	NC	F	61.0	août-57	2019/07/05	2019/07/05	50.0	75.0	...	2.0	2.0	3.0	1
3	4	1	GE	F	65.0	juil.-53	2019/07/10	2019/07/10	54.0	80.0	...	1.0	0.0	2.0	1
4	5	1	ML	F	59.0	oct.-58	2019/07/17	2019/07/17	51.0	69.0	...	1.0	2.0	3.0	2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
220	221	14	GM	F	65.0	mai-55	2022/03/10	2022/03/11	70.0	80.0	...	2.0	2.0	2.0	1
221	222	15	MM	M	76.0	févr.-45	2022/06/02	2022/06/02	80.0	100.0	...	0.0	0.0	2.0	0
222	223	15	PA	F	64.0	nov.-56	2022/06/21	2022/06/21	45.0	70.0	...	0.0	2.0	3.0	0
223	224	15	TL	M	60.0	févr.-61	2022/06/30	2022/06/30	40.0	70.0	...	2.0	0.0	0.0	2
224	225	15	MC	F	45.0	nov.-76	2022/07/19	2022/07/19	88.0	90.0	...	2.0	2.0	1.0	1

225 rows × 292 columns

In [4]:
```
dataset.shape
```

Out[4]:(225, 292)

In [5]:
```
print(dataset.columns.tolist())
```

['N°de_Patient', 'Centre ', 'Initiales', 'Sexe', 'Age', 'Date_Naissance', 'Date_visite1', 'Date_visite2', 'EVA_mean', 'EVA_max', 'Inclusion1', 'Inclusion2', 'Inclusion 3', 'Inclusion4', 'Inclusion5', 'Inclusion6', 'Inclusion7', 'Non_Inclusion1', 'Non_Inclusion2', 'Non_Inclusion3', 'Non_Inclusion4', 'MOCA1', 'MOCA2', 'MOCA3', 'M OCA4', 'MOCA5', 'MOCA6', 'MOCA7', 'MOCA8', 'MOCA9', 'MOCA10', 'MOCA_Total', 'item', 'item1', 'item2', 'item3', 'item4', 'item5', 'item6', 'item7', 'item8', 'item 9', 'item10', 'item11', 'item12', 'item13', 'item14', 'item15', 'item16', 'item17', 'item18', 'item19', 'item20', 'item21', 'item22', 'item23', 'item24', 'item25', 'item26', 'ite m27', 'item28', 'item29', 'item30', 'item31', 'item32', 'item33', 'Douleur_Centrale', 'DN4.1', 'DN4.2', 'DN4.3', 'DN4.4', 'DN4.5', 'DN4.6', 'DN4.7', 'DN4.8', 'DN4.9', ' DN4.10', 'DN4.Total', 'KPPS1_s', 'KPPS1_f', 'Domain1_Total', 'KPPS2_s', 'KPPS2_f', 'KPPS3_s', 'KPPS3_f', 'Domain2_Total', 'KPPS4_s', 'KPPS4_f', 'KPPS5 _s', 'KPPS5_f', 'KPPS6_s', 'KPPS6_f', 'Domain3_Total', 'KPPS7_s', 'KPPS7_f', 'KPPS8_s', 'KPPS8_f', 'Domain4_Total', 'KPPS9_s', 'KPPS9_f', 'KPPS10_s', ' KPPS10_f', 'KPPS11_s', 'KPPS11_f', 'Domain5_Total', 'KPPS12_s', 'KPPS12_f', 'KPPS13_s', 'KPPS13_f', 'Domain6_Total', 'KPPS14_s', 'KPPS14_f', 'Domai n7_Total', 'KPPS_Total_Score', 'MDS_UPDRS1.A', 'MDS_UPDRS1.1', 'MDS_UPDRS1.2', 'MDS_UPDRS1.3', 'MDS_UPDRS1.4', 'MDS_UPDRS1.5', 'MDS_U PDRS1.6', 'MDS_UPDRS1.6a', 'MDS_UPDRS1.7', 'MDS_UPDRS1.8', 'MDS_UPDRS1.9', 'MDS_UPDRS1.10', 'MDS_UPDRS1.11', 'MDS_UPDRS1.12', 'MDS _UPDRS1.13', 'P1_MDS_UPDRS', 'MDS_UPDRS2.1', 'MDS_UPDRS2.2', 'MDS_UPDRS2.3', 'MDS_UPDRS2.4', 'MDS_UPDRS2.5', 'MDS_UPDRS2.6', 'MDS _UPDRS2.7', 'MDS_UPDRS2.8', 'MDS_UPDRS2.9', 'MDS_UPDRS2.10', 'MDS_UPDRS2.11', 'MDS_UPDRS2.12', 'MDS_UPDRS2.13', 'P2_MDS_UPDRS', ' MDS_UPDRS3a', 'MDS_UPDRS3b', 'MDS_UPDRS3c', 'MDS_UPDRS3.C1', 'MDS_UPDRS3.1', 'MDS_UPDRS3.2', 'MDS_UPDRS3.3a', 'MDS_UPDRS3.3b', ' MDS_UPDRS3.3c', 'MDS_UPDRS3.3d', 'MDS_UPDRS3.3e', 'MDS_UPDRS3.4a', 'MDS_UPDRS3.4b', 'MDS_UPDRS3.5a', 'MDS_UPDRS3.5b', 'MDS_UPDR S3.6a', 'MDS_UPDRS3.6b', 'MDS_UPDRS3.7a', 'MDS_UPDRS3.7b', 'MDS_UPDRS3.8a', 'MDS_UPDRS3.8b', 'MDS_UPDRS3.9', 'MDS_UPDRS3.10', 'MDS _UPDRS3.11', 'MDS_UPDRS3.12', 'MDS_UPDRS3.13', 'MDS_UPDRS3.14', 'MDS_UPDRS3.15a', 'MDS_UPDRS3.15b', 'MDS_UPDRS3.16a', 'MDS_UPDR S3.16b', 'MDS_UPDRS3.17a', 'MDS_UPDRS3.17b', 'MDS_UPDRS3.17c', 'MDS_UPDRS3.17d', 'MDS_UPDRS3.17e', 'MDS_UPDRS3.18', 'P3_MDS_UPDR S', 'MDS_UPDRSdiskiné', 'MDS_UPDRSinterféré', 'MDS_UPDRS_Hoehn&Yahr', 'MDS_UPDRS4.1', 'MDS_UPDRS4.2', 'MDS_UPDRS4.3', 'MDS_UPDRS4.4 ', 'MDS_UPDRS4.5', 'MDS_UPDRS4.6', 'P4_MDS_UPDRS', 'MDS_UPDS_Total', 'McGilla1', 'McGilla2', 'McGilla3', 'McGilla4', 'McGilla5', 'McGilla6', 'McGilla7' , 'McGilla8', 'McGilla9', 'McGilla10', 'McGilla11', 'McGilla12', 'McGilla13', 'McGilla14', 'McGilla15', 'McGillb', 'McGill_Total', 'BPIa', 'BPIb', 'BPIc', 'BPId', 'BPIe', 'B PIf', 'BPIg', 'BPI_Total', 'PCS1', 'PCS2', 'PCS3', 'PCS4', 'PCS5', 'PCS6', 'PCS7', 'PCS8', 'PCS9', 'PCS10', 'PCS11', 'PCS12', 'PCS13', 'PCS_Total', 'PDQ1', 'P DQ2', 'PDQ3', 'PDQ4', 'PDQ5', 'PDQ6', 'PDQ7', 'PDQ8', 'PDQ9', 'PDQ10', 'PDQ11', 'PDQ12', 'PDQ13', 'PDQ14', 'PDQ15', 'PDQ16', 'PDQ17', 'PDQ18', 'PDQ19 ', 'PDQ20', 'PDQ21', 'PDQ22', 'PDQ23', 'PDQ24', 'PDQ25', 'PDQ26', 'PDQ27', 'PDQ28', 'PDQ29', 'PDQ30', 'PDQ31', 'PDQ32', 'PDQ33', 'PDQ34', 'PDQ35', 'P DQ36', 'PDQ37', 'PDQ38', 'PDQ39', 'PDQ_Total', 'PDQ_Score_Complète', ' PDQ_Résultat_Pourcentage', 'HADa.1', 'HADd.1', 'HADa.2', 'HADd.2', 'HADa.3', ' HADd.3', 'HADa.4', 'HADd.4', 'HADa.5', 'HADd.5', 'HADa.6', 'HADd.6', 'HADa.7', 'HADd.7', 'Anxiété_Total', 'Depression_Total', 'Total_Score', 'Conformité_au_ protocol']

In [6]:
```
df= dataset[['item1', 'item2', 'item3', 'item4', 'item5', 'item6', 'item7', 'item8', 'item9', 'item10', 'item11', 'item12', 'item13', 'item14', 'item15', 'item16', 'item17
'item19', 'item20', 'item21', 'item22', 'item23', 'item24', 'item25', 'item26', 'item27', 'item28','Douleur_Centrale']]
df
```

Out[6]:

	item1	item2	item3	item4	item5	item6	item7	item8	item9	item10	...	item20	item21	item22	item23	item24	item25	item26	item27	item28
0	0.0	1.0	1	0.0	1	0	1.0	0	0.0	0	...	0	0	1	1	0	1	0	0	0
1	1.0	0.0	0	1.0	0	0	1.0	1	0.0	0	...	0	0	1	1	1	1	1	0	0
2	0.0	0.0	0	0.0	1	0	1.0	0	0.0	0	...	0	0	0	0	0	0	1	0	0
3	0.0	1.0	1	0.0	0	0	1.0	0	1.0	0	...	0	0	0	1	1	0	0	0	0
4	1.0	0.0	1	1.0	1	0	0.0	1	0.0	0	...	0	1	0	1	1	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
220	0.0	1.0	1	0.0	0	0	1.0	1	0.0	0	...	0	0	1	1	1	1	1	0	0
221	1.0	1.0	1	0.0	1	0	1.0	0	0.0	0	...	0	0	0	1	1	1	0	1	0
222	0.0	0.0	0	0.0	0	0	0.0	0	1.0	1	...	0	0	0	1	1	0	0	0	0
223	0.0	0.0	0	0.0	1	0	0.0	1	0.0	1	...	0	0	1	1	1	1	1	1	0
224	1.0	0.0	0	0.0	1	1	1.0	0	0.0	0	...	1	1	1	1	1	1	1	1	1

225 rows × 29 columns

In [7]:
```
df.shape
```

Out[7]:(225, 29)

Objectif :

1- Prédire la variable Y qui est la douleur centrale
2- Sortir les items qui expliquent le mieux mon Y

In [8]:
```
from IPython.display import Image

# Afficher l'image
Image(filename="C:/Users/aliah/Downloads/Capture d'écran 2023-04-21 140544.png")
```

Out[8]:

item1	Numeric	12	0	Présente-t-elle un Brûlure ?
item2	Numeric	12	0	un Etau
item3	Numeric	1	0	une compression
item4	Numeric	12	0	des décharges électriques
item5	Numeric	1	0	des Elancements
item6	Numeric	1	0	Froid douleureux
item7	Numeric	12	0	Crampe
item8	Numeric	1	0	Douleur sourde
item9	Numeric	12	0	coups de couteau
item10	Numeric	1	0	Piqûre
item11	Numeric	12	0	Broiement
item12	Numeric	1	0	Profonde
item13	Numeric	1	0	Lancinante
item14	Numeric	12	0	est-elle associée aux Fourmillements ?
item15	Numeric	1	0	est-elle associée aux picotements
item16	Numeric	1	0	est-elle associée aux Démangeaisons
item17	Numeric	12	0	est-elle associée aux Engourdissement
item18	Numeric	12	0	La douleur est augmenté par le Forttement sur la zone douleureuse ?
item19	Numeric	1	0	La douleur est augmenté par le pression sur la zone douleureuse
item20	Numeric	1	0	La douleur est augmenté par le contact acen un objet froid sur la zone douleureuse
item21	Numeric	1	0	La douleur est augmenté par le contact acen un objet chaud sur la zone douleureuse
item22	Numeric	1	0	Elle était le premier symptôme de la maladie ?
item23	Numeric	1	0	Elle se situe du coté le plus aateint de la maladie
item24	Numeric	1	0	Elle augmente quand l'état moteur s'aggrave
item25	Numeric	1	0	Elle s'ameliore par la prise des médicaments antiparkinsoniens
item26	Numeric	1	0	Elle est présente la nuit
item27	Numeric	1	0	Elle est présente de façon diffuse sur vôtre corps
item28	Numeric	1	0	Elle se déplace d'un endroit à l'autre de vôtre corps
DE1	Numeric	12	0	Une étiologie traumatique, orthopédique ou rhumatologique ?
DE2	Numeric	1	0	Est-elle musculo-squelettique ?
DE3	Numeric	1	0	Est-elle de type radiculaire ?
DE4	Numeric	1	0	Est elle dûe à la syndrome des jampes sans repos ?
DE5	Numeric	1	0	Est-elle dtstonique ?
Diagnostic_...	Numeric	12	0	La douleur Parkinsonienne Centrale

Vérifier le type de chaque variable

In [9]:
```
df.select_dtypes(object).columns
```

Out[9]:
```
Index(['item3', 'item5', 'item6', 'item8', 'item10', 'item12', 'item13',
       'item15', 'item16', 'item19', 'item20', 'item21', 'item22', 'item23',
       'item24', 'item25', 'item26', 'item27', 'item28'],
      dtype='object')
```

Conversion de toutes les variables en float

In [10]:
```
# Convertir les colonnes object en float
for col in df.columns:
    if df[col].dtype == 'object':
        df[col] = pd.to_numeric(df[col], errors='coerce')

# Afficher les types de données des colonnes
print(df.dtypes)
```

```
item1              float64
item2              float64
item3              float64
item4              float64
item5              float64
item6              float64
item7              float64
item8              float64
item9              float64
item10             float64
item11             float64
item12             float64
item13             float64
item14             float64
item15             float64
item16             float64
item17             float64
item18             float64
item19             float64
item20             float64
item21             float64
item22             float64
item23             float64
item24             float64
item25             float64
item26             float64
item27             float64
item28             float64
Douleur_Centrale    float64
dtype: object
C:\Users\aliah\AppData\Local\Temp\ipykernel_9448\1561378193.py:4: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  df[col] = pd.to_numeric(df[col], errors='coerce')
```

Gestion des données manquantes

In [11]:
```
#Compter le nombre de valeurs manquantes par variable
missing_values_count = df.isnull().sum()

# Afficher le nombre de valeurs manquantes par variable
print("Nombre de valeurs manquantes par variable :\n", missing_values_count)

# Afficher les variables qui contiennent des valeurs manquantes
missing_variables = df.columns[df.isnull().any()].tolist()
print("\nVariables avec des valeurs manquantes :", missing_variables)
```

```
Nombre de valeurs manquantes par variable :
 item1             8
item2              8
item3              8
item4              8
item5             10
item6             10
item7              7
item8              8
item9              8
item10             9
item11             8
item12            10
item13             9
item14             6
item15             7
item16             7
item17             6
item18             7
item19             8
item20             7
item21             8
item22             8
item23             9
item24            11
item25             8
item26             8
item27             9
item28             7
Douleur_Centrale   5
dtype: int64

Variables avec des valeurs manquantes : ['item1', 'item2', 'item3', 'item4', 'item5', 'item6', 'item7', 'item8', 'item9', 'item10', 'item11', 'item12', 'item13', 'item14', 'it
em15', 'item16', 'item17', 'item18', 'item19', 'item20', 'item21', 'item22', 'item23', 'item24', 'item25', 'item26', 'item27', 'item28', 'Douleur_Centrale']
In [12]: df.isnull().sum().sum()

Out[12]:232
```

Interpretation pour savoir la manière manière de gérer les nan

Cependant, il est important de noter que l'imputation par la moyenne peut ne pas être la méthode la plus appropriée pour gérer les données manquantes dans un jeu de données, en particulier pour les variables binaires. Il existe d'autres méthodes d'imputation telles que la médiane, le mode ou la méthode KNN qui peuvent mieux convenir à ce type de données.

IMPUTATION par la méthode KNN (k-Nearest Neighbors)

La méthode KNN (k-Nearest Neighbors) est une méthode d'imputation de données manquantes basée sur les données existantes. Elle consiste à remplacer chaque valeur manquante dans une variable par la valeur de la variable la plus proche, en termes de distance euclidienne, des k échantillons les plus proches de la variable contenant la valeur manquante.

In [13]:
```
from sklearn.impute import KNNImputer

# Imputer les valeurs manquantes avec KNN
imputer = KNNImputer(n_neighbors=5)
imputed_data = imputer.fit_transform(df)

# Convertir les données imputées en DataFrame
df_imputed = pd.DataFrame(imputed_data, columns=df.columns)

# Renommer les colonnes
column_names = list(df.columns)
for i in range(len(column_names)):
    df_imputed.rename(columns={i: column_names[i]}, inplace=True)

# Afficher le DataFrame imputé avec les noms de colonnes corrects
print(df_imputed)
```

	item1	item2	item3	item4	item5	item6	item7	item8	item9	item10	\
0	0.0	1.0	1.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	
1	1.0	0.0	0.0	1.0	0.0	0.0	1.0	1.0	0.0	0.0	
2	0.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	
3	0.0	1.0	1.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0	
4	1.0	0.0	1.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0	
..	...	...	...	...	...	...	...	...	...	...	
220	0.0	1.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	
221	1.0	1.0	1.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	
222	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	1.0	
223	0.0	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	
224	1.0	0.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0	0.0	

	...	item20	item21	item22	item23	item24	item25	item26	item27	\
0	...	0.0	0.0	1.0	1.0	0.0	1.0	0.0	0.0	
1	...	0.0	0.0	1.0	1.0	1.0	1.0	1.0	0.0	
2	...	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	
3	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	
4	...	0.0	1.0	0.0	1.0	1.0	0.0	0.0	0.0	
..	...	...	...	...	...	...	...	...	...	
220	...	0.0	0.0	1.0	1.0	1.0	1.0	1.0	0.0	
221	...	0.0	0.0	0.0	1.0	1.0	1.0	0.0	1.0	
222	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	
223	...	0.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0	
224	...	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	

	item28	Douleur_Centrale
0	0.0	1.0
1	0.0	1.0
2	0.0	0.0
3	0.0	0.0
4	0.0	1.0
..	...	...
220	0.0	0.0
221	0.0	1.0
222	0.0	1.0
223	0.0	1.0
224	1.0	1.0

[225 rows x 29 columns]

Commentaire :

Le paramètre n_neighbors égal à 5, qui spécifie le nombre de voisins à considérer lors de l'imputation

In [14]:
```
#Compter le nombre de valeurs manquantes par variable
missing_values_count = df_imputed.isnull().sum()

# Afficher le nombre de valeurs manquantes par variable
print("Nombre de valeurs manquantes par variable :\n", missing_values_count)

# Afficher les variables qui contiennent des valeurs manquantes
missing_variables = df_imputed.columns[df.isnull().any()].tolist()
print("\nVariables avec des valeurs manquantes :", missing_variables)
```

```
Nombre de valeurs manquantes par variable :
 item1            0
item2             0
item3             0
item4             0
item5             0
item6             0
item7             0
item8             0
item9             0
item10            0
item11            0
item12            0
item13            0
item14            0
item15            0
item16            0
item17            0
item18            0
item19            0
item20            0
item21            0
item22            0
item23            0
item24            0
item25            0
item26            0
item27            0
item28            0
Douleur_Centrale    0
dtype: int64

Variables avec des valeurs manquantes : ['item1', 'item2', 'item3', 'item4', 'item5', 'item6', 'item7', 'item8', 'item9', 'item10', 'item11', 'item12', 'item13', 'item14', 'it
em15', 'item16', 'item17', 'item18', 'item19', 'item20', 'item21', 'item22', 'item23', 'item24', 'item25', 'item26', 'item27', 'item28', 'Douleur_Centrale']
In [15]: df_imputed.isnull().sum().sum()

Out[15]:0
In [16]: df_imputed
```

Out[16]:

	item1	item2	item3	item4	item5	item6	item7	item8	item9	item10	...	item20	item21	item22	item23	item24	item25	item26	item27	item2
0	0.0	1.0	1.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	1.0	1.0	0.0	1.0	0.0	0.0	0
1	1.0	0.0	0.0	1.0	0.0	0.0	1.0	1.0	0.0	0.0	...	0.0	0.0	1.0	1.0	1.0	1.0	1.0	0.0	0
2	0.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0
3	0.0	1.0	1.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0
4	1.0	0.0	1.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0	...	0.0	1.0	0.0	1.0	1.0	0.0	0.0	0.0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
220	0.0	1.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	...	0.0	0.0	1.0	1.0	1.0	1.0	1.0	0.0	0
221	1.0	1.0	1.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	0.0	1.0	1.0	1.0	0.0	1.0	0
222	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	1.0	...	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0
223	0.0	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	...	0.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0	0
224	1.0	0.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0	0.0	...	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1

225 rows × 29 columns

Voir comment mes données sont distribuées

Les variables binaires ne peuvent pas être analysées avec les mêmes méthodes que les variables continues. En effet, les variables binaires ne peuvent prendre que deux valeurs possibles (0 ou 1), ce qui signifie que la distribution ne peut pas être représentée par une courbe de densité, un histogramme ou un diagramme en boîte.

Cependant, il est toujours important de comprendre comment les valeurs sont réparties dans votre ensemble de données. Pour les variables binaires, vous pouvez calculer la proportion de 0 et de 1 dans votre jeu de données, ainsi que la fréquence de chaque catégorie. Vous pouvez également utiliser des tableaux de contingence pour voir comment les variables binaires sont associées les unes aux autres.

En résumé, la meilleure façon de comprendre comment les variables binaires sont distribuées est de calculer les proportions et les fréquences, et de les comparer à d'autres variables binaires pour voir comment elles sont associées.

In [17]:
```
# Voir la distribution pour chaque variable
for col in df_imputed.columns:
    if df_imputed[col].dtype == 'float64':
        df_imputed[col] = df_imputed[col].astype(int)
    zeros = np.count_nonzero(df_imputed[col] == 0)
    ones = np.count_nonzero(df_imputed[col] == 1)
    print(f"Variable {col}:")
```

```
        print(f"Nombre de 0 : {zeros}")
        print(f"Nombre de 1 : {ones}")
        print(f"Proportion de 0 : {zeros/len(df_imputed[col])}")
        print(f"Proportion de 1 : {ones/len(df_imputed[col])}")
        print(f"Fréquence de 0 : {zeros/(zeros+ones)}")
        print(f"Fréquence de 1 : {ones/(zeros+ones)}")
        print("")
```

```
Variable item1:
Nombre de 0 : 149
Nombre de 1 : 76
Proportion de 0 : 0.6622222222222223
Proportion de 1 : 0.3377777777777778
Fréquence de 0 : 0.6622222222222223
Fréquence de 1 : 0.3377777777777778

Variable item2:
Nombre de 0 : 123
Nombre de 1 : 102
Proportion de 0 : 0.5466666666666666
Proportion de 1 : 0.4533333333333333
Fréquence de 0 : 0.5466666666666666
Fréquence de 1 : 0.4533333333333333

Variable item3:
Nombre de 0 : 103
Nombre de 1 : 122
Proportion de 0 : 0.4577777777777778
Proportion de 1 : 0.5422222222222223
Fréquence de 0 : 0.4577777777777778
Fréquence de 1 : 0.5422222222222223

Variable item4:
Nombre de 0 : 162
Nombre de 1 : 63
Proportion de 0 : 0.72
Proportion de 1 : 0.28
Fréquence de 0 : 0.72
Fréquence de 1 : 0.28

Variable item5:
Nombre de 0 : 119
Nombre de 1 : 106
Proportion de 0 : 0.5288888888888889
Proportion de 1 : 0.4711111111111111
Fréquence de 0 : 0.5288888888888889
Fréquence de 1 : 0.4711111111111111

Variable item6:
Nombre de 0 : 206
Nombre de 1 : 19
Proportion de 0 : 0.9155555555555556
Proportion de 1 : 0.08444444444444445
Fréquence de 0 : 0.9155555555555556
Fréquence de 1 : 0.08444444444444445

Variable item7:
Nombre de 0 : 117
Nombre de 1 : 108
Proportion de 0 : 0.52
Proportion de 1 : 0.48
Fréquence de 0 : 0.52
Fréquence de 1 : 0.48

Variable item8:
Nombre de 0 : 103
Nombre de 1 : 122
Proportion de 0 : 0.4577777777777778
Proportion de 1 : 0.5422222222222223
Fréquence de 0 : 0.4577777777777778
Fréquence de 1 : 0.5422222222222223

Variable item9:
Nombre de 0 : 159
Nombre de 1 : 66
Proportion de 0 : 0.7066666666666667
Proportion de 1 : 0.29333333333333333
Fréquence de 0 : 0.7066666666666667
Fréquence de 1 : 0.29333333333333333

Variable item10:
Nombre de 0 : 187
Nombre de 1 : 38
```

Proportion de 0 : 0.8311111111111111
Proportion de 1 : 0.1688888888888889
Fréquence de 0 : 0.8311111111111111
Fréquence de 1 : 0.1688888888888889

Variable item11:
Nombre de 0 : 181
Nombre de 1 : 44
Proportion de 0 : 0.8044444444444444
Proportion de 1 : 0.19555555555555557
Fréquence de 0 : 0.8044444444444444
Fréquence de 1 : 0.19555555555555557

Variable item12:
Nombre de 0 : 75
Nombre de 1 : 150
Proportion de 0 : 0.3333333333333333
Proportion de 1 : 0.6666666666666666
Fréquence de 0 : 0.3333333333333333
Fréquence de 1 : 0.6666666666666666

Variable item13:
Nombre de 0 : 74
Nombre de 1 : 151
Proportion de 0 : 0.3288888888888889
Proportion de 1 : 0.6711111111111111
Fréquence de 0 : 0.3288888888888889
Fréquence de 1 : 0.6711111111111111

Variable item14:
Nombre de 0 : 148
Nombre de 1 : 77
Proportion de 0 : 0.6577777777777778
Proportion de 1 : 0.3422222222222222
Fréquence de 0 : 0.6577777777777778
Fréquence de 1 : 0.3422222222222222

Variable item15:
Nombre de 0 : 166
Nombre de 1 : 59
Proportion de 0 : 0.7377777777777778
Proportion de 1 : 0.26222222222222225
Fréquence de 0 : 0.7377777777777778
Fréquence de 1 : 0.26222222222222225

Variable item16:
Nombre de 0 : 210
Nombre de 1 : 15
Proportion de 0 : 0.9333333333333333
Proportion de 1 : 0.06666666666666667
Fréquence de 0 : 0.9333333333333333
Fréquence de 1 : 0.06666666666666667

Variable item17:
Nombre de 0 : 106
Nombre de 1 : 119
Proportion de 0 : 0.4711111111111111
Proportion de 1 : 0.5288888888888889
Fréquence de 0 : 0.4711111111111111
Fréquence de 1 : 0.5288888888888889

Variable item18:
Nombre de 0 : 185
Nombre de 1 : 40
Proportion de 0 : 0.8222222222222222
Proportion de 1 : 0.17777777777777778
Fréquence de 0 : 0.8222222222222222
Fréquence de 1 : 0.17777777777777778

Variable item19:
Nombre de 0 : 132
Nombre de 1 : 93
Proportion de 0 : 0.5866666666666667
Proportion de 1 : 0.41333333333333333
Fréquence de 0 : 0.5866666666666667
Fréquence de 1 : 0.41333333333333333

Variable item20:
Nombre de 0 : 209
Nombre de 1 : 16
Proportion de 0 : 0.9288888888888889
Proportion de 1 : 0.07111111111111111
Fréquence de 0 : 0.9288888888888889

Fréquence de 0 : 0.9288888888888889
Fréquence de 1 : 0.07111111111111111

Variable item21:
Nombre de 0 : 203
Nombre de 1 : 22
Proportion de 0 : 0.9022222222222223
Proportion de 1 : 0.09777777777777778
Fréquence de 0 : 0.9022222222222223
Fréquence de 1 : 0.09777777777777778

Variable item22:
Nombre de 0 : 170
Nombre de 1 : 55
Proportion de 0 : 0.7555555555555555
Proportion de 1 : 0.24444444444444444
Fréquence de 0 : 0.7555555555555555
Fréquence de 1 : 0.24444444444444444

Variable item23:
Nombre de 0 : 108
Nombre de 1 : 117
Proportion de 0 : 0.48
Proportion de 1 : 0.52
Fréquence de 0 : 0.48
Fréquence de 1 : 0.52

Variable item24:
Nombre de 0 : 82
Nombre de 1 : 143
Proportion de 0 : 0.36444444444444446
Proportion de 1 : 0.6355555555555555
Fréquence de 0 : 0.36444444444444446
Fréquence de 1 : 0.6355555555555555

Variable item25:
Nombre de 0 : 110
Nombre de 1 : 115
Proportion de 0 : 0.4888888888888889
Proportion de 1 : 0.5111111111111111
Fréquence de 0 : 0.4888888888888889
Fréquence de 1 : 0.5111111111111111

Variable item26:
Nombre de 0 : 83
Nombre de 1 : 142
Proportion de 0 : 0.3688888888888889
Proportion de 1 : 0.6311111111111111
Fréquence de 0 : 0.3688888888888889
Fréquence de 1 : 0.6311111111111111

Variable item27:
Nombre de 0 : 158
Nombre de 1 : 67
Proportion de 0 : 0.7022222222222222
Proportion de 1 : 0.29777777777777775
Fréquence de 0 : 0.7022222222222222
Fréquence de 1 : 0.29777777777777775

Variable item28:
Nombre de 0 : 166
Nombre de 1 : 59
Proportion de 0 : 0.7377777777777778
Proportion de 1 : 0.26222222222222225
Fréquence de 0 : 0.7377777777777778
Fréquence de 1 : 0.26222222222222225

Variable Douleur_Centrale:
Nombre de 0 : 144
Nombre de 1 : 81
Proportion de 0 : 0.64
Proportion de 1 : 0.36
Fréquence de 0 : 0.64
Fréquence de 1 : 0.36

In [18]:
```
import matplotlib.pyplot as plt
import seaborn as sns

fig, axes = plt.subplots(nrows=7, ncols=4, figsize=(15, 20))
for i, ax in enumerate(axes.flatten()):
    if i < len(df_imputed.columns):
        col = df_imputed.columns[i]
```

```
        ax.hist(df_imputed[col])
        ax.set_title(col)
plt.tight_layout()
plt.show()
```

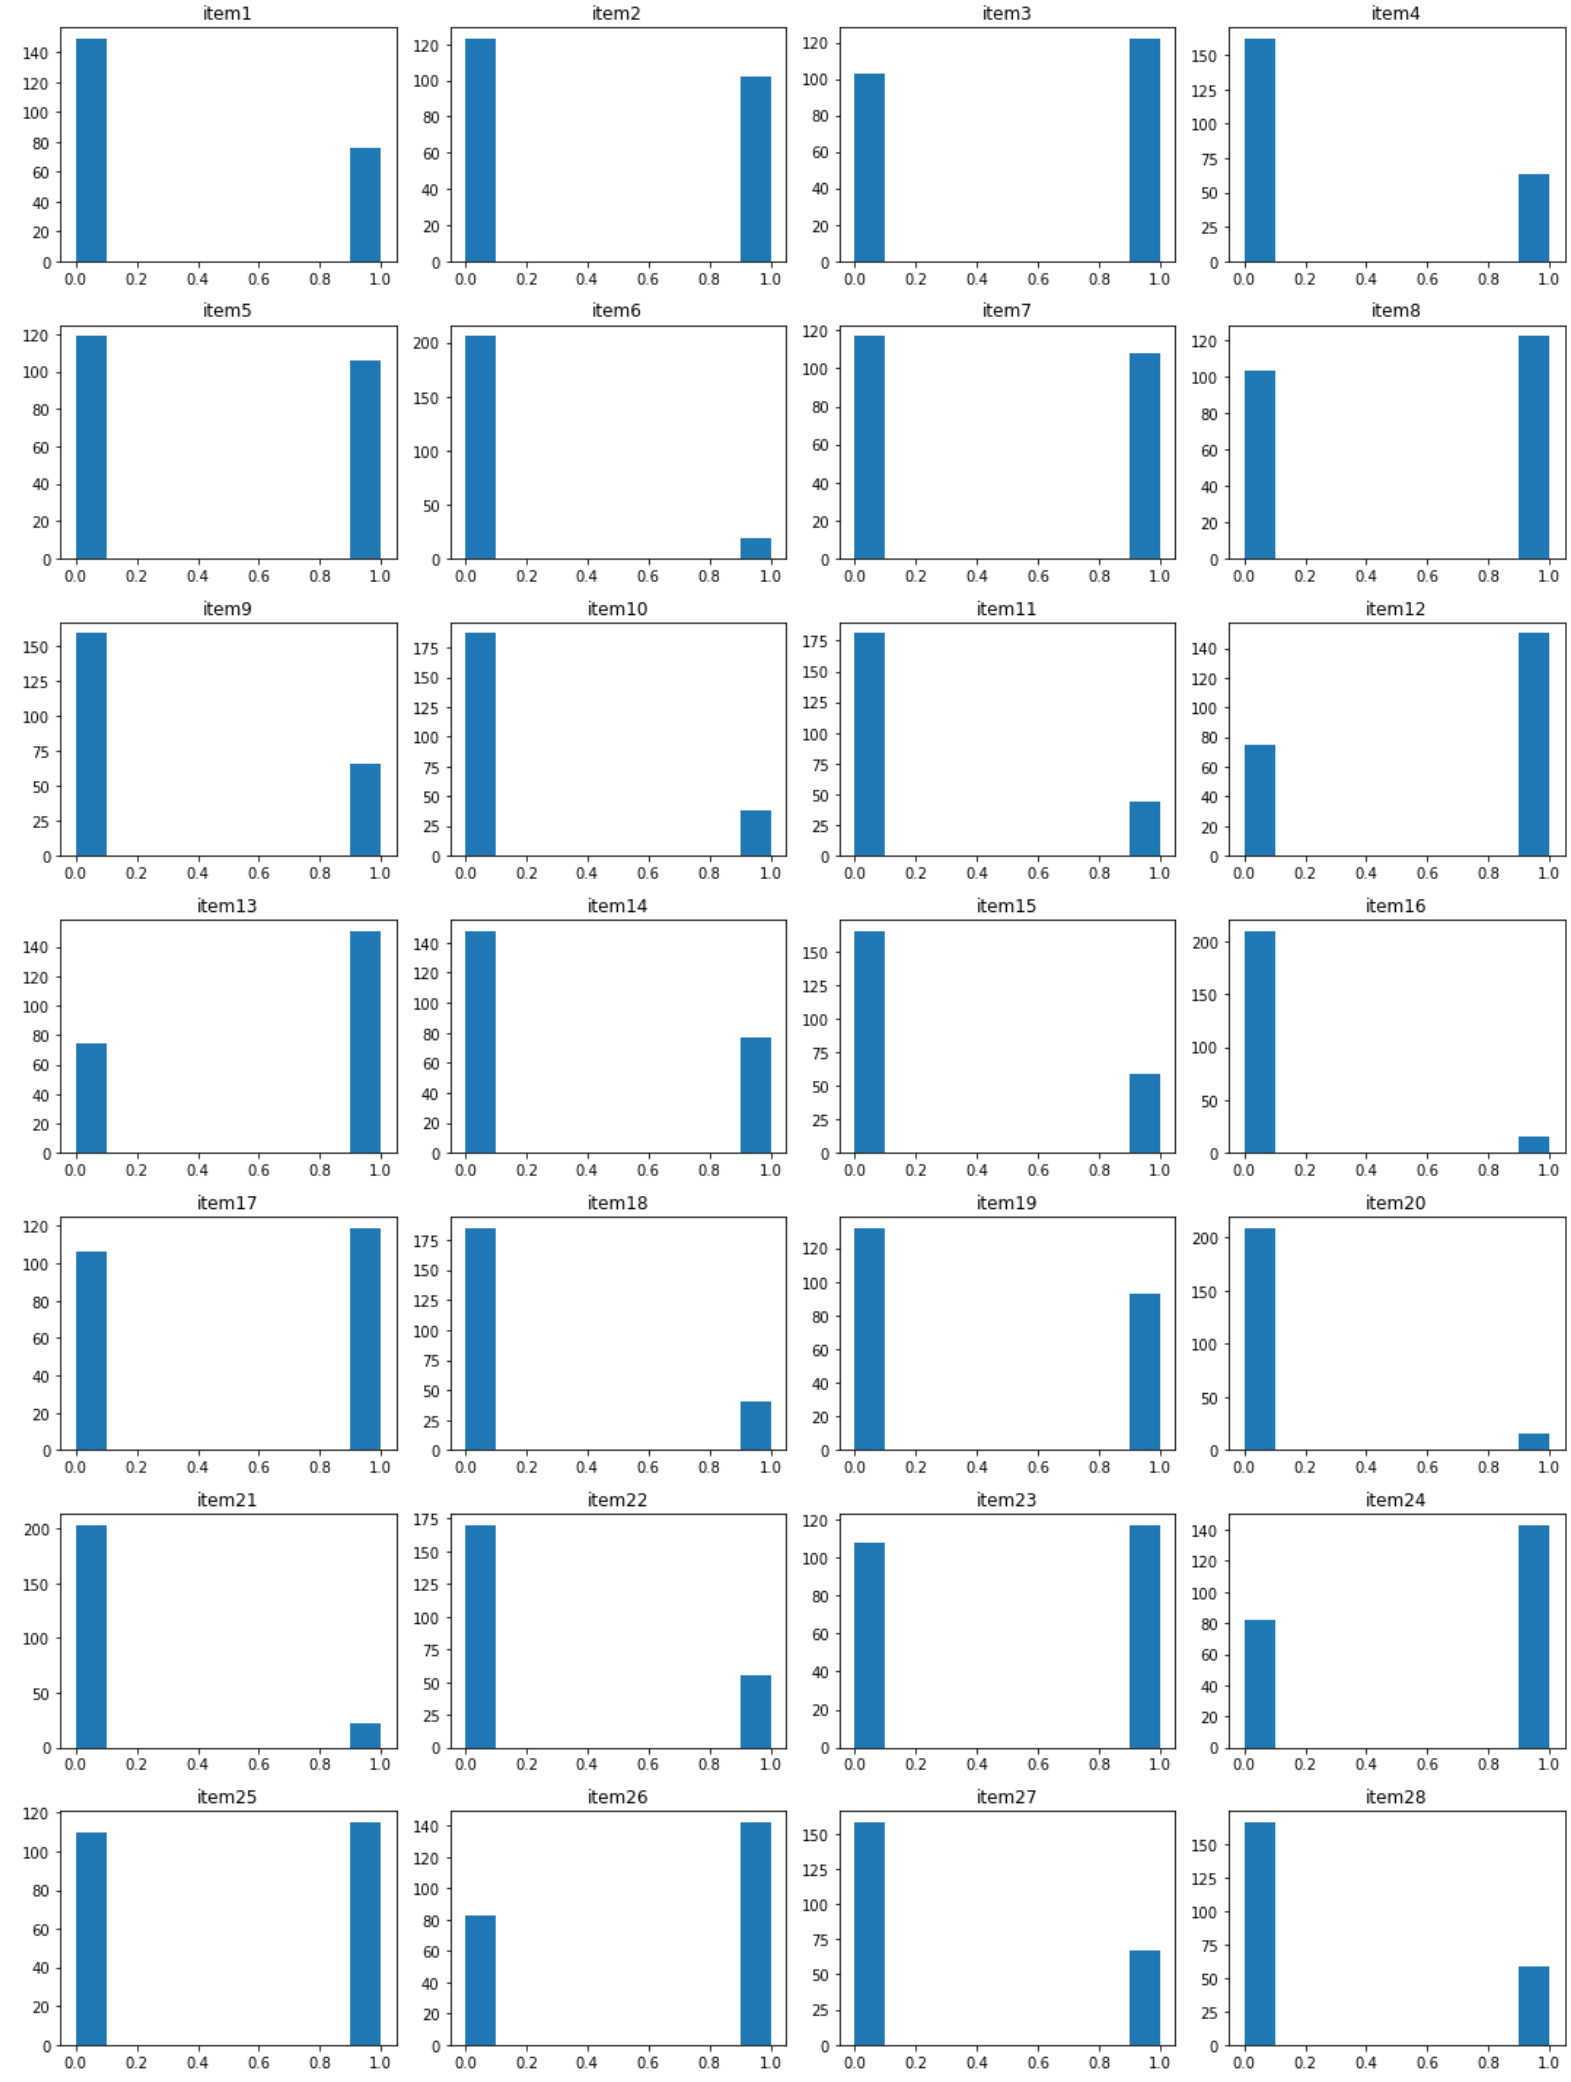

MODELISATION

In [19]:
```
# 1) Créer une matrice des variables indépendantes et le vecteur de la variable dépendante.
# X est la matrice et Y est le vecteur
# La matrice des variables indépendantes est aussi appeelée matrice de featuresμ

X = df_imputed.drop('Douleur_Centrale', axis=1)  # Supprimer la colonne "target" de la matrice X
Y = df_imputed['Douleur_Centrale']               # Sélectionner uniquement la colonne "target" pour Y
```

In [20]:
```
X
```

Out[20]:

	item1	item2	item3	item4	item5	item6	item7	item8	item9	item10	...	item19	item20	item21	item22	item23	item24	item25	item26	item2
0	0	1	1	0	1	0	1	0	0	0	...	0	0	0	1	1	0	1	0	
1	1	0	0	1	0	0	1	1	0	0	...	0	0	0	1	1	1	1	1	
2	0	0	0	0	1	0	1	0	0	0	...	1	0	0	0	0	0	0	1	
3	0	1	1	0	0	0	1	0	1	0	...	1	0	0	0	1	1	0	0	
4	1	0	1	1	1	0	0	1	0	0	...	1	0	1	0	1	1	0	0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
220	0	1	1	0	0	0	1	1	0	0	...	1	0	0	1	1	1	1	1	
221	1	1	1	0	1	0	1	0	0	0	...	0	0	0	0	1	1	1	0	
222	0	0	0	0	0	0	0	0	1	1	...	1	0	0	0	1	1	0	0	
223	0	0	0	0	1	0	0	1	0	1	...	0	0	0	1	1	1	1	1	
224	1	0	0	0	1	1	1	0	0	0	...	1	1	1	1	1	1	1	1	

225 rows × 28 columns

In [21]:
```
Y
```

Out[21]:
```
0      1
1      1
2      0
3      0
4      1
      ..
220    0
221    1
222    1
223    1
224    1
Name: Douleur_Centrale, Length: 225, dtype: int32
```

Rééquilibré mon jeu de données par la méthode SMOT

La sur-échantillonnage de la classe minoritaire (oversampling): cela consiste à ajouter des copies d'observations de la classe minoritaire pour atteindre un équilibre avec la classe majoritaire. Cette technique peut être réalisée à l'aide de méthodes telles que la duplication aléatoire ou la génération synthétique de données (SMOTE)

SMOTE (Synthetic Minority Over-sampling Technique) est une méthode d'oversampling qui consiste à créer des exemples synthétiques de la classe minoritaire en interpolant de manière aléatoire les échantillons existants. Elle permet d'augmenter la taille de la classe minoritaire sans générer de copies exactes des échantillons existants, ce qui peut améliorer la généralisation du modèle

In [22]:
```
!pip install imbalanced-learn
```

```
Requirement already satisfied: imbalanced-learn in c:\users\aliah\anaconda3\envs\pythonproject\lib\site-packages (0.10.1)
Requirement already satisfied: threadpoolctl>=2.0.0 in c:\users\aliah\anaconda3\envs\pythonproject\lib\site-packages (from imbalanced-learn) (2.2.0)
Requirement already satisfied: scikit-learn>=1.0.2 in c:\users\aliah\anaconda3\envs\pythonproject\lib\site-packages (from imbalanced-learn) (1.0.2)
Requirement already satisfied: joblib>=1.1.1 in c:\users\aliah\anaconda3\envs\pythonproject\lib\site-packages (from imbalanced-learn) (1.1.1)
Requirement already satisfied: scipy>=1.3.2 in c:\users\aliah\anaconda3\envs\pythonproject\lib\site-packages (from imbalanced-learn) (1.7.3)
Requirement already satisfied: numpy>=1.17.3 in c:\users\aliah\anaconda3\envs\pythonproject\lib\site-packages (from imbalanced-learn) (1.21.5)
```

In [23]:
```
from imblearn.over_sampling import SMOTE

# Créer un objet SMOTE
smote = SMOTE()

# Appliquer SMOTE sur les données
X_resampled, Y_resampled = smote.fit_resample(X, Y)
```

In [24]:
```
# Vérifier la distribution des classes avant et après rééquilibrage
fig, axs = plt.subplots(ncols=2, figsize=(12,6))
sns.countplot(Y, ax=axs[0])
sns.countplot(Y_resampled, ax=axs[1])
axs[0].set_title("Avant rééquilibrage")
axs[1].set_title("Après rééquilibrage")
plt.show()
```

```
C:\Users\aliah\anaconda3\envs\PythonProject\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass the following variable as a keyword arg: x.
From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit keyword will result in an error or misinterp
retation.
  warnings.warn(
C:\Users\aliah\anaconda3\envs\PythonProject\lib\site-packages\seaborn\_decorators.py:36: FutureWarning: Pass the following variable as a keyword arg: x.
From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit keyword will result in an error or misinterp
retation.
  warnings.warn(
```

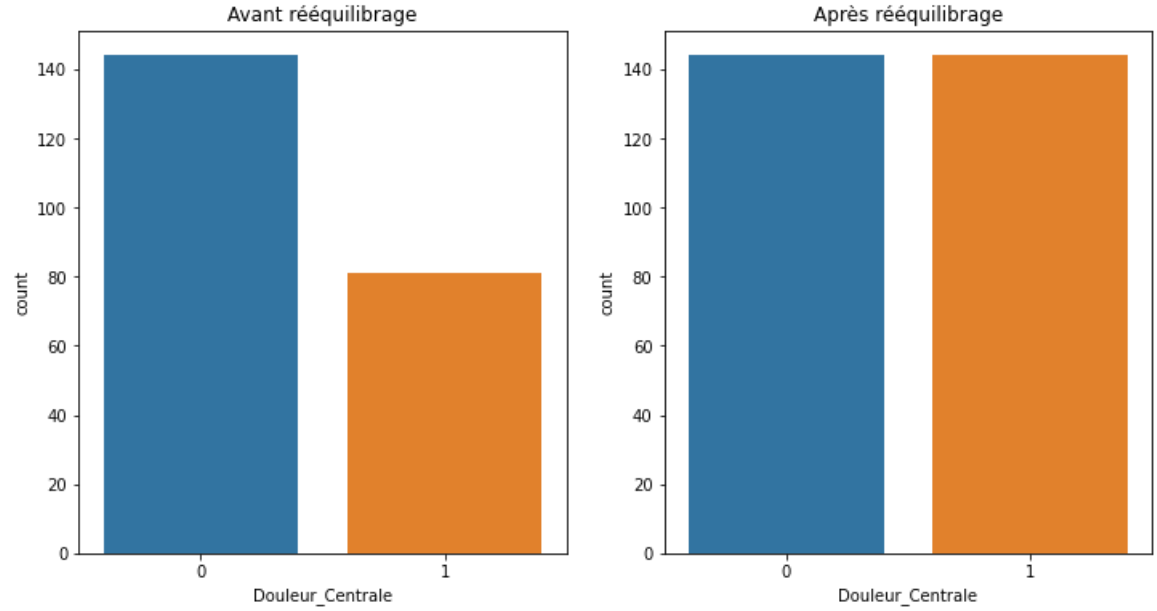

In [25]:
```
# Afficher la distribution des variables de X après rééquilibrage
X_resampled.hist(figsize=(20,20))
plt.show()
```

Séparation du dataset en training_set et en test_set

In [26]:
```
from sklearn.model_selection import train_test_split

X_train, X_test, Y_train, Y_test = train_test_split(X_resampled, Y_resampled, test_size = 1/3, random_state= 0)

# Calculer la proportion de chaque ensemble
train_prop = len(X_train) / len(X)
test_prop = len(X_test) / len(X)

print("Proportion de données dans l'ensemble d'entraînement: {:.2f}".format(train_prop))
print("Proportion de données dans l'ensemble de test: {:.2f}".format(test_prop))
```

```
Proportion de données dans l'ensemble d'entraînement: 0.85
Proportion de données dans l'ensemble de test: 0.43
```

1- Regression Logistique

In [29]:
```
from sklearn.linear_model import LogisticRegression

# Créer le modèle de régression logistique
classifier = LogisticRegression(penalty='l1', C=0.1, solver='liblinear', random_state=0)

# Entraîner le modèle sur les données d'entraînement
```

```
classifier.fit(X_train, Y_train)


# Afficher les coefficients de la régression logistique pour chaque variable explicative
print("Coefficients de la régression logistique :")
for i in range(len(X.columns)):
    print(X.columns[i], ": ", classifier.coef_[0][i])
```

```
Coefficients de la régression logistique :
item1 :  0.0
item2 :  0.0
item3 :  0.0
item4 :  0.0
item5 :  -0.24745964367188664
item6 :  0.0
item7 :  0.0
item8 :  0.0
item9 :  0.0
item10 :  0.0
item11 :  0.0
item12 :  0.0
item13 :  0.0
item14 :  0.0
item15 :  0.0
item16 :  0.0
item17 :  0.0
item18 :  0.0
item19 :  0.0
item20 :  0.0
item21 :  0.0
item22 :  0.0
item23 :  0.0
item24 :  0.16709613072810298
item25 :  0.0
item26 :  0.0
item27 :  0.0
item28 :  0.0
```

In [31]:
```
# Faire des prédictions sur les données de test
Y_pred = classifier.predict(X_test)
Y_pred
```

```
Out[31]:array([0, 0, 1, 0, 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0,
       0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0,
       1, 0, 0, 0, 0, 1, 1, 1, 1, 0, 0, 1, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0,
       0, 0, 0, 1, 0, 0, 1, 1, 0, 1, 0, 0, 0, 0, 1, 0, 1, 1, 0, 1, 1, 0,
       1, 0, 1, 1, 0, 1, 0, 1])
```

Matrice de confusion

In [32]:
```
from sklearn.metrics import confusion_matrix
CM = confusion_matrix(Y_test, Y_pred)
CM
```

```
Out[32]:array([[37,  8],
       [26, 25]], dtype=int64)
```

In [33]:
```
group_names = ['True Neg','False Pos','False Neg','True Pos']
group_counts = ['{0:0.0f}'.format(value) for value in
                CM.flatten()]
group_percentages = ['{0:.2%}'.format(value) for value in
                     CM.flatten()/np.sum(CM)]
labels = [f'{v1}\n{v2}\n{v3}' for v1, v2, v3 in
          zip(group_names,group_counts,group_percentages)]
labels = np.asarray(labels).reshape(2,2)
sns.heatmap(CM, annot=labels, fmt='', cmap='Blues')
```

Out[33]:<AxesSubplot:>

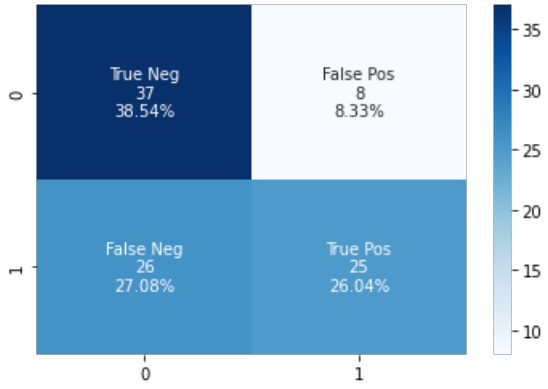

Courbe ROC

In [35]:
```
from sklearn import metrics
y_pred_proba = classifier.predict_proba(X_test)[::,1]
fpr, tpr, _ = metrics.roc_curve(Y_test,  y_pred_proba)
auc = metrics.roc_auc_score(Y_test, y_pred_proba)
plt.plot(fpr,tpr,label="df2, auc="+str(auc))
plt.legend(loc=4)
plt.show()
```

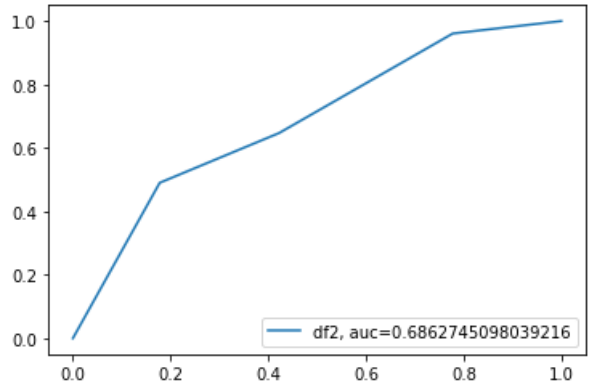

La courbe ROC (Receiver Operating Characteristic) est un graphique du taux de vrais positifs par rapport au taux de faux positifs. Il montre le compromis entre sensibilité et spécificité.

Metrics

In [36]:
```
from sklearn.metrics import accuracy_score
from sklearn.metrics import f1_score
from sklearn.metrics import precision_score, recall_score
from sklearn.metrics import cohen_kappa_score
from sklearn.metrics import matthews_corrcoef
from sklearn import metrics
```

In [37]:
```
Accuracy_Rate = accuracy_score(Y_test, Y_pred)
Error_rate = 1 - Accuracy_Rate
F1_score_logreg = f1_score(Y_test, Y_pred)
precision = precision_score(Y_test, Y_pred)
recall = recall_score(Y_test, Y_pred)
CK = cohen_kappa_score (Y_test,Y_pred)
MC = matthews_corrcoef(Y_test,Y_pred)
auc = metrics.roc_auc_score(Y_test, y_pred_proba)

print("precision : {:.2f}".format(precision))
print("recall : {:.2f}".format(recall))
print("Accuracy rate: ", Accuracy_Rate)
print("Error rate: ", Error_rate)
print("F1_score: ", F1_score_logreg)
print("CK:", CK)
print("MC:", MC)
print("AUC:", auc)
```

```
precision : 0.76
recall : 0.49
Accuracy rate:  0.6458333333333334
Error rate:  0.35416666666666663
F1_score:  0.5952380952380952
CK: 0.3052362707535121
MC: 0.3282468492164149
AUC: 0.6862745098039216
```

In [38]:
```
# create a list of metric names and values
metric_names = ["Precision", "Recall", "Accuracy Rate", "Error Rate", "F1 Score", "CK", "MC","AUC"]
metric_values = [precision, recall, Accuracy_Rate, Error_rate, F1_score_logreg, CK, MC,auc]

# create a bar chart
fig, ax = plt.subplots(figsize=(8,6))
ax.bar(metric_names, metric_values)
ax.set_ylabel('Value')
ax.set_ylim([0,1])
ax.set_title('Performance Metrics')
plt.show()
```

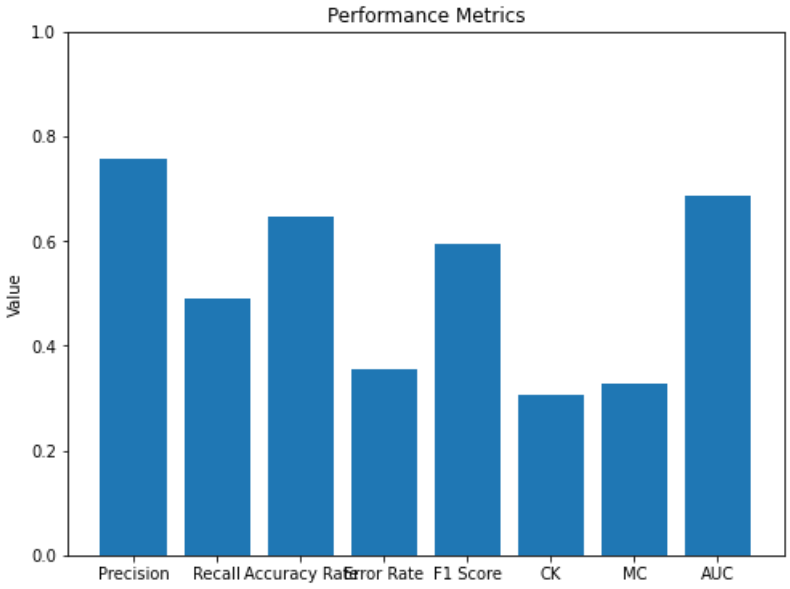

2- Decision Tree

In [39]:
```
from sklearn.tree import DecisionTreeClassifier
from boruta import BorutaPy

# Initialisation et entraînement du modèle d'arbre de décision
tree = DecisionTreeClassifier(random_state=0)
tree.fit(X_train, Y_train)
```

Out[39]:DecisionTreeClassifier(random_state=0)

In [40]:
```
Y_pred2 = tree.predict(X_test)
Y_pred2
```

Out[40]:
```
array([0, 1, 0, 0, 1, 0, 1, 1, 0, 1, 0, 1, 1, 0, 1, 1, 1, 1, 0, 0, 0, 0,
       0, 1, 1, 0, 1, 1, 1, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 1, 0, 1, 1, 0,
       0, 1, 0, 1, 0, 1, 1, 1, 1, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 1, 0, 0,
       1, 0, 1, 1, 1, 1, 1, 1, 0, 1, 0, 1, 0, 0, 1, 1, 0, 1, 0, 1, 1, 0,
       1, 1, 1, 1, 1, 1, 0, 1])
```

Matrice de confusion

In [41]:
```
CM2 = confusion_matrix(Y_test, Y_pred2)
CM2
```

Out[41]:
```
array([[29, 16],
       [16, 35]], dtype=int64)
```

In [42]:
```
group_names = ['True Neg','False Pos','False Neg','True Pos']
group_counts = ['{0:0.0f}'.format(value) for value in
                CM2.flatten()]
group_percentages = ['{0:.2%}'.format(value) for value in
                     CM2.flatten()/np.sum(CM2)]
labels = [f'{v1}\n{v2}\n{v3}' for v1, v2, v3 in
          zip(group_names,group_counts,group_percentages)]
labels = np.asarray(labels).reshape(2,2)
sns.heatmap(CM2, annot=labels, fmt='', cmap='coolwarm')
```

Out[42]:<AxesSubplot:>

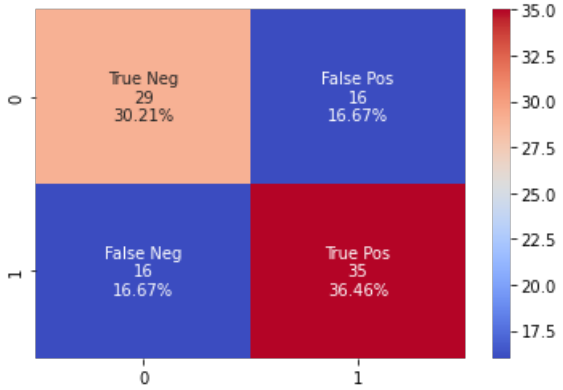

Courbe roc

In [43]:
```
y_pred_proba2 = tree.predict_proba(X_test)[::,1]
fpr, tpr, _ = metrics.roc_curve(Y_test,  y_pred_proba2)
auc = metrics.roc_auc_score(Y_test, y_pred_proba2)
plt.plot(fpr,tpr,label="df2, auc="+str(auc))
```

```
plt.legend(loc=4)
plt.show()
```

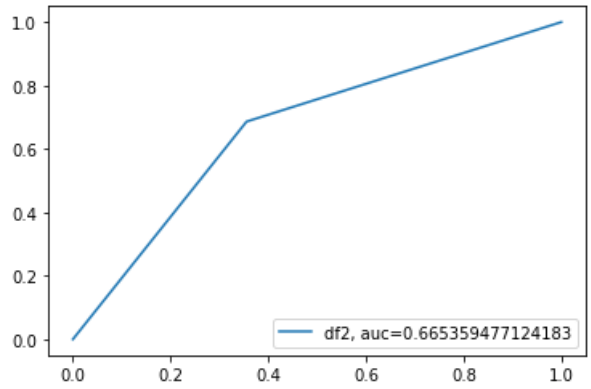

Metrics

In [44]:
```
Accuracy_Rate2 = accuracy_score(Y_test, Y_pred2)
Error_rate2 = 1 - Accuracy_Rate2  # Change variable name to Error_rate2
F1_score_logreg2 = f1_score(Y_test, Y_pred2)
precision2 = precision_score(Y_test, Y_pred2)
recall2 = recall_score(Y_test, Y_pred2)
CK2 = cohen_kappa_score(Y_test, Y_pred2)
MC2 = matthews_corrcoef(Y_test, Y_pred2)
auc2 = metrics.roc_auc_score(Y_test, y_pred_proba2)

print("precision : {:.2f}".format(precision2))
print("recall : {:.2f}".format(recall2))
print("Accuracy rate: ", Accuracy_Rate2)
print("Error rate: ", Error_rate2)
print("F1_score: ", F1_score_logreg2)
print("CK:", CK2)
print("MC:", MC2)
print("AUC:", auc2)
```

```
precision : 0.69
recall : 0.69
Accuracy rate:  0.6666666666666666
Error rate:  0.33333333333333337
F1_score:  0.6862745098039216
CK: 0.33071895424836606
MC: 0.330718954248366
AUC: 0.665359477124183
```

In [45]:
```
# create a list of metric names and values
metric_names = ["Precision", "Recall", "Accuracy Rate", "Error Rate", "F1 Score", "CK", "MC","AUC"]
metric_values = [precision2, recall2, Accuracy_Rate2, Error_rate2, F1_score_logreg2, CK2, MC2,auc2]

# create a bar chart
fig, ax = plt.subplots(figsize=(8,6))
ax.bar(metric_names, metric_values)
ax.set_ylabel('Value')
ax.set_ylim([0,1])
ax.set_title('Performance Metrics')
plt.show()
```

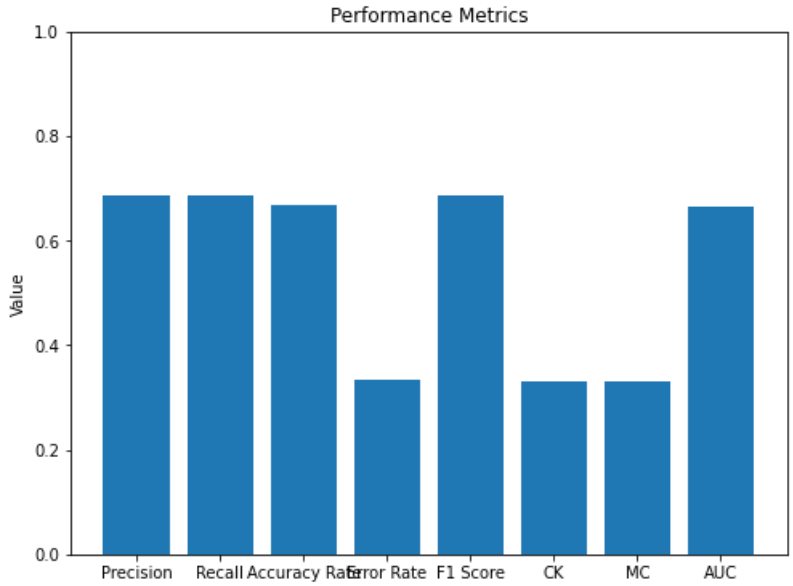

3- RandomForest

In [110]:
```
import shap
from sklearn.ensemble import RandomForestClassifier

# Création de l'estimateur RandomForestClassifier
rf = RandomForestClassifier(n_estimators=1000, n_jobs=1, max_depth=5)

# Entrainement du modèle sur les données d'entrainement
rf.fit(X_train, Y_train)

# Prédiction sur les données de test
Y_pred = rf.predict(X_test)
```

MAX_DEPTH

Le paramètre max_depth est un hyperparamètre utilisé dans les arbres de décision et les forêts aléatoires. Il contrôle la profondeur maximale de l'arbre. Plus précisément, max_depth définit le nombre maximum de niveaux que l'arbre de décision peut avoir, c'est-à-dire le nombre maximal de divisions de l'arbre.

Une valeur plus élevée de max_depth permet à l'arbre d'être plus complexe et d'apprendre des modèles plus détaillés à partir des données d'entraînement. Cependant, cela peut également conduire à un surajustement (overfitting) si la profondeur devient trop grande.

Il est courant de régler max_depth en fonction de la taille et de la complexité des données, ainsi que de la quantité d'informations que vous souhaitez extraire de l'arbre. Une valeur par défaut est souvent utilisée, mais il est recommandé d'expérimenter avec différentes valeurs pour trouver celle qui fonctionne le mieux pour votre problème spécifique.

In [49]:
```
Y_pred3 = rf.predict(X_test)
print(Y_test)
print(Y_pred3)
```

```
55     0
182    1
92     1
208    0
278    1
      ..
71     0
179    1
231    1
194    0
276    1
Name: Douleur_Centrale, Length: 96, dtype: int32
[0 0 1 0 1 0 1 1 0 1 1 1 0 0 1 1 0 1 0 1 1 1 0 1 0 0 0 1 1 0 0 0 1 0 0 1 0
 1 0 1 0 0 1 0 1 1 0 0 0 0 1 1 1 1 0 1 0 1 1 0 0 0 0 1 0 0 1 0 1 1 0 0 1 1
 0 1 0 0 0 0 1 0 1 1 0 1 1 0 1 0 1 1 0 1 1 0]
```

Matrice de confusion

In [50]:
```
CM3 = confusion_matrix(Y_test, Y_pred3)
CM3
```

Out[50]:
```
array([[34, 11],
       [15, 36]], dtype=int64)
```

In [51]:
```
group_names = ['True Neg','False Pos','False Neg','True Pos']
group_counts = ['{0:0.0f}'.format(value) for value in
                CM3.flatten()]
group_percentages = ['{0:.2%}'.format(value) for value in
                     CM3.flatten()/np.sum(CM3)]
labels = [f'{v1}\n{v2}\n{v3}' for v1, v2, v3 in
          zip(group_names,group_counts,group_percentages)]
labels = np.asarray(labels).reshape(2,2)
sns.heatmap(CM3, annot=labels, fmt='', cmap='Pastel1')
```

Out[51]:<AxesSubplot:>

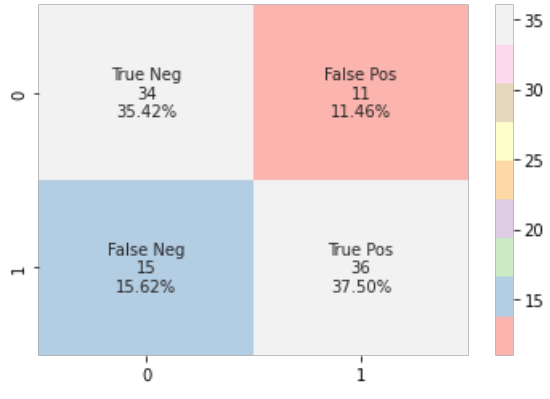

In [52]:
```
print(Y_test.shape)
print(CM3)
```

```
(96,)
[[34 11]
 [15 36]]
```

Courbe roc

In [55]:
```
Y_pred3_proba = rf.predict_proba(X_test)[::,1]
fpr, tpr, _ = metrics.roc_curve(Y_test,Y_pred3_proba)
auc = metrics.roc_auc_score(Y_test, Y_pred3_proba)
plt.plot(fpr,tpr,label="df2, auc="+str(auc))
plt.legend(loc=4)  #Y6_pred = model.predict(X_test_selected)
plt.show()
# La courbe roc montre la spécifité et la sensibilité
```

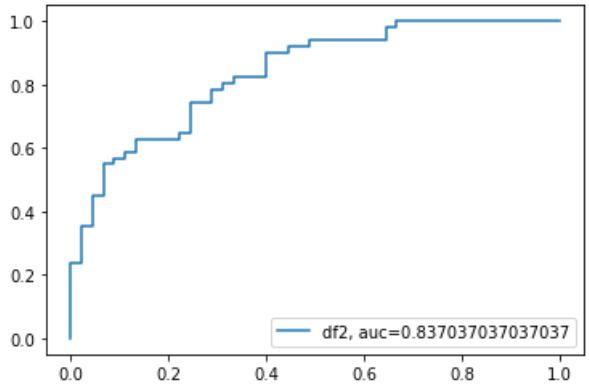

Metrics

In [56]:
```
Accuracy_Rate3 = accuracy_score(Y_test, Y_pred3)
Error_rate3 = 1 - Accuracy_Rate3  # Change variable name to Error_rate2
F1_score_logreg3 = f1_score(Y_test, Y_pred3)
precision3 = precision_score(Y_test, Y_pred3)
recall3 = recall_score(Y_test, Y_pred3)
CK3 = cohen_kappa_score(Y_test, Y_pred3)
MC3 = matthews_corrcoef(Y_test, Y_pred3)
auc3 = metrics.roc_auc_score(Y_test, Y_pred3)


print("precision : {:.2f}".format(precision3))
print("recall : {:.2f}".format(recall3))
print("Accuracy rate: ", Accuracy_Rate3)
print("Error rate: ", Error_rate3)
print("F1_score: ", F1_score_logreg3)
print("CK:", CK3)
print("MC:", MC3)
print("AUC:", auc3)
```

```
precision : 0.77
recall : 0.71
Accuracy rate:  0.7291666666666666
Error rate:  0.27083333333333337
F1_score:  0.7346938775510204
CK: 0.459037711313394
MC: 0.46063575594147665
AUC: 0.7307189542483661
```

In [57]:
```
# create a list of metric names and values
metric_names = ["Precision", "Recall", "Accuracy Rate", "Error Rate", "F1 Score", "CK", "MC","AUC"]
metric_values = [precision3, recall3, Accuracy_Rate3, Error_rate3, F1_score_logreg3, CK3, MC3,auc3]

# create a bar chart
fig, ax = plt.subplots(figsize=(8,6))
ax.bar(metric_names, metric_values)
ax.set_ylabel('Value')
ax.set_ylim([0,1])
ax.set_title('Performance Metrics')
plt.show()
```

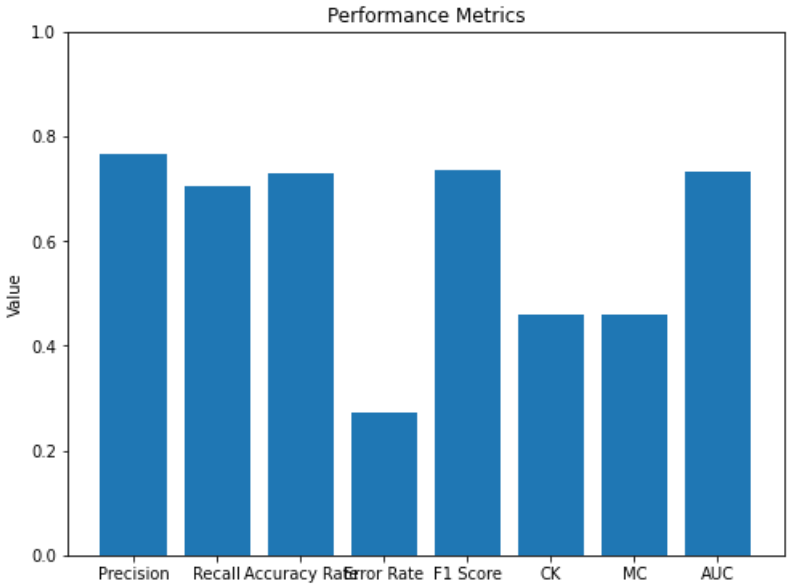

4- Gradient Boosting

In [58]:
```
from sklearn.ensemble import GradientBoostingClassifier

# Création de l'estimateur GradientBoostingClassifier
gb = GradientBoostingClassifier(n_estimators=100, max_depth=5)

# Entrainement du modèle sur les données d'entrainement
gb.fit(X_train, Y_train)

# Evaluation du modèle sur les données de test
accuracy = gb.score(X_test, Y_test)
print("Accuracy:", accuracy)

# Affichage de l'importance des features
importances = pd.DataFrame({'Feature': X_train.columns, 'Importance': gb.feature_importances_})
importances = importances.sort_values(by='Importance', ascending=False)
print(importances)
```

```
Accuracy: 0.7604166666666666
   Feature  Importance
23  item24    0.107479
11  item12    0.085572
25  item26    0.084538
4    item5    0.059557
14  item15    0.051415
12  item13    0.049186
7    item8    0.044464
10  item11    0.044157
24  item25    0.042746
26  item27    0.041801
6    item7    0.041158
18  item19    0.036753
0    item1    0.036114
22  item23    0.033701
2    item3    0.027990
21  item22    0.026930
27  item28    0.026221
8    item9    0.024237
16  item17    0.023587
13  item14    0.022378
17  item18    0.018468
9   item10    0.018013
3    item4    0.011079
19  item20    0.010841
5    item6    0.010531
15  item16    0.009202
1    item2    0.006470
20  item21    0.005412
```

In [60]:
```
Y_pred4 =gb.predict(X_test)
print(Y_test)
print(Y_pred4)
```

```
55    0
182   1
92    1
208   0
278   1
     ..
71    0
179   1
231   1
194   0
276   1
Name: Douleur_Centrale, Length: 96, dtype: int32
[0 0 1 0 1 0 1 1 0 1 1 1 1 0 1 1 1 1 0 1 1 1 0 0 1 0 0 1 1 0 0 0 1 0 0 1 0
 1 0 1 0 1 1 0 1 1 1 0 0 1 1 1 1 1 0 1 0 1 1 1 0 0 1 0 0 0 1 0 0 1 0 1 1 1
 0 1 0 0 0 0 1 0 1 1 0 1 1 0 1 1 1 0 1 1 0 1]
```

Matrice de confusion

In [61]:
```
CM4 = confusion_matrix(Y_test, Y_pred4)
CM4
```

Out[61]:
```
array([[32, 13],
       [10, 41]], dtype=int64)
```

In [62]:
```
group_names = ['True Neg','False Pos','False Neg','True Pos']
group_counts = ['{0:0.0f}'.format(value) for value in
                CM4.flatten()]
group_percentages = ['{0:.2%}'.format(value) for value in
                     CM4.flatten()/np.sum(CM4)]
labels = [f'{v1}\n{v2}\n{v3}' for v1, v2, v3 in
          zip(group_names,group_counts,group_percentages)]
labels = np.asarray(labels).reshape(2,2)
sns.heatmap(CM4, annot=labels, fmt='', cmap='crest')
```

Out[62]:<AxesSubplot:>

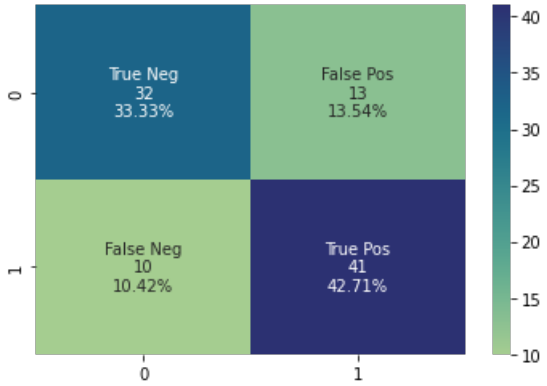

In [63]:
```
print(Y_test.shape)
print(CM4)
```

```
(96,)
[[32 13]
 [10 41]]
```

Courbe roc

In [65]:
```
Y_pred_proba4 = gb.predict_proba(X_test)[::,1]
fpr, tpr, _ = metrics.roc_curve(Y_test,Y_pred_proba4)
auc = metrics.roc_auc_score(Y_test, Y_pred_proba4)
plt.plot(fpr,tpr,label="df2, auc="+str(auc))
plt.legend(loc=4)  #Y6_pred = model.predict(X_test_selected)
plt.show()
# La courbe roc montre la spécifité et la sensibilité
```

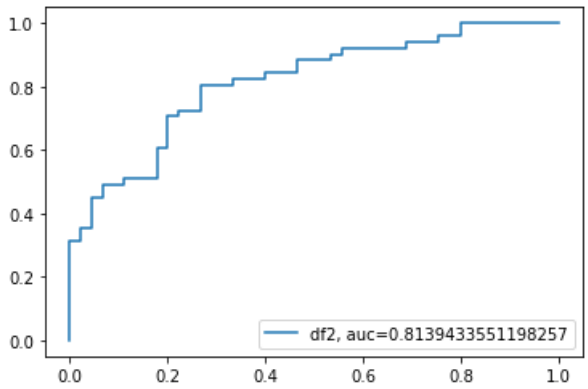

In [66]:
```
Accuracy_Rate4 = accuracy_score(Y_test, Y_pred4)
Error_rate4 = 1 - Accuracy_Rate4  # Change variable name to Error_rate2
```

```
F1_score_logreg4 = f1_score(Y_test, Y_pred4)
precision4 = precision_score(Y_test, Y_pred4)
recall4 = recall_score(Y_test, Y_pred4)
CK4 = cohen_kappa_score(Y_test, Y_pred4)
MC4 = matthews_corrcoef(Y_test, Y_pred4)
auc4 = metrics.roc_auc_score(Y_test, Y_pred4)

print("precision : {:.2f}".format(precision4))
print("recall : {:.2f}".format(recall4))
print("Accuracy rate: ", Accuracy_Rate4)
print("Error rate: ", Error_rate4)
print("F1_score: ", F1_score_logreg4)
print("CK:", CK4)
print("MC:", MC4)
print("AUC:", auc4)
```

```
precision : 0.76
recall : 0.80
Accuracy rate:  0.7604166666666666
Error rate:  0.23958333333333337
F1_score:  0.780952380952381
CK: 0.5170603674540682
MC: 0.518089280340204
AUC: 0.7575163398692811
```

Commentaire

Il est possible que l'application d'un algorithme de sélection de caractéristiques sur vos modèles de régression logistique, arbre de décision, SVM et gradient boosting n'ait pas fonctionné dans votre cas. Cela peut être dû à plusieurs raisons :

Le choix de l'algorithme de sélection de caractéristiques peut ne pas être adapté à votre jeu de données ou à votre modèle en particulier. Chaque algorithme de sélection de caractéristiques a ses propres avantages et inconvénients, et certains peuvent mieux fonctionner que d'autres selon le type de modèle que vous utilisez et la nature de vos données.

Le nombre de caractéristiques dans votre jeu de données peut être trop petit pour bénéficier de l'application d'un algorithme de sélection de caractéristiques. Dans ce cas, les performances de votre modèle peuvent être pires après la sélection de caractéristiques car vous avez potentiellement supprimé des caractéristiques utiles.

Les performances de votre modèle peuvent dépendre de la façon dont les caractéristiques sont sélectionnées. Si les caractéristiques sélectionnées ne sont pas les plus pertinentes pour votre modèle, cela peut conduire à de moins bonnes performances.

En résumé, l'application d'un algorithme de sélection de caractéristiques n'est pas une solution universelle pour améliorer les performances de votre modèle. Il est important de choisir l'algorithme de sélection de caractéristiques approprié à votre modèle et à votre jeu de données, et de comprendre comment les caractéristiques sélectionnées affectent les performances de votre modèle.

Test de chi2 pour le choix des variables les plus pertinentes

In [90]:
```
df_imputed.columns
```

Out[90]:
```
Index(['item1', 'item2', 'item3', 'item4', 'item5', 'item6', 'item7', 'item8',
       'item9', 'item10', 'item11', 'item12', 'item13', 'item14', 'item15',
       'item16', 'item17', 'item18', 'item19', 'item20', 'item21', 'item22',
       'item23', 'item24', 'item25', 'item26', 'item27', 'item28',
       'Douleur_Centrale'],
      dtype='object')
```

In [111]:
```
from scipy.stats import chi2_contingency

# Liste des noms de colonnes de variables binaires
binary_vars = ['item1', 'item2', 'item3', 'item4', 'item5', 'item6', 'item7', 'item8',
'item9', 'item10', 'item11', 'item12', 'item13', 'item14', 'item15',
'item16', 'item17', 'item18', 'item19', 'item20', 'item21', 'item22',
'item23', 'item24', 'item25', 'item26', 'item27', 'item28']

selected_vars = []
for var in binary_vars:
    contingency_table = pd.crosstab(df_imputed[var], df_imputed['Douleur_Centrale'])
    chi2, p, dof, expected = chi2_contingency(contingency_table)
    if p < 0.05:
        selected_vars.append(var)
    print(f"Variable {var}: chi2 = {chi2:.3f}, p = {p:.3f}")

print("Selected variables:", selected_vars)
```

Variable item1: chi2 = 2.278, p = 0.131
Variable item2: chi2 = 2.600, p = 0.107
Variable item3: chi2 = 4.465, p = 0.035
Variable item4: chi2 = 0.968, p = 0.325
Variable item5: chi2 = 5.806, p = 0.016
Variable item6: chi2 = 0.688, p = 0.407
Variable item7: chi2 = 1.650, p = 0.199
Variable item8: chi2 = 0.194, p = 0.660
Variable item9: chi2 = 0.989, p = 0.320
Variable item10: chi2 = 0.191, p = 0.662
Variable item11: chi2 = 0.868, p = 0.352
Variable item12: chi2 = 1.063, p = 0.302
Variable item13: chi2 = 0.002, p = 0.967
Variable item14: chi2 = 5.187, p = 0.023
Variable item15: chi2 = 1.810, p = 0.179
Variable item16: chi2 = 0.003, p = 0.956
Variable item17: chi2 = 1.037, p = 0.309
Variable item18: chi2 = 0.160, p = 0.689
Variable item19: chi2 = 0.076, p = 0.782
Variable item20: chi2 = 0.000, p = 1.000
Variable item21: chi2 = 2.803, p = 0.094
Variable item22: chi2 = 9.827, p = 0.002
Variable item23: chi2 = 11.845, p = 0.001
Variable item24: chi2 = 18.788, p = 0.000
Variable item25: chi2 = 22.574, p = 0.000
Variable item26: chi2 = 0.469, p = 0.493
Variable item27: chi2 = 1.054, p = 0.305
Variable item28: chi2 = 0.000, p = 1.000
Selected variables: ['item3', 'item5', 'item14', 'item22', 'item23', 'item24', 'item25']
In [112]: print("Selected variables:", selected_vars)

Selected variables: ['item3', 'item5', 'item14', 'item22', 'item23', 'item24', 'item25']

Commentaires

La valeur de p obtenue pour chaque variable indique la probabilité que la variable binaire et la variable de sortie soient indépendantes. Si la valeur de p est inférieure à un certain seuil (généralement 0,2). On peut rejeter l'hypothèse nulle d'indépendance et conclure qu'il existe une corrélation significative entre les deux variables.

ACP : Analyse en Composante Principale